

Ravena AI — Sistema Cognitivo Modular

Relatório de Potencialização V2.0 — Abril 2026

Este documento detalha as implementações de infraestrutura e inteligência realizadas para elevar a Ravena AI ao nível de um **Agente de Ação Soberano**, com capacidades reais de processamento, busca e execução.

1. Arquitetura de Memória: ChromaDB Real & Persistente

Substituímos o sistema de simulação (*mock*) por uma implementação real de banco de dados vetorial.

Recurso	Descrição	Impacto
Persistência Local	Armazenamento físico na pasta <code>./chroma_db</code> .	O conhecimento não é mais perdido ao reiniciar o sistema.
Busca Vetorial	Utilização de similaridade de cosseno com embeddings <code>all-MiniLM-L6-v2</code> .	Recuperação de documentos com precisão semântica superior.
Suporte Remoto	Integração com <code>HttpClient</code> para conexões em nuvem.	Permite que a Ravena escale para infraestruturas distribuídas.

2. Motor de Inferência: Suporte a Multi-Modelos (LoRA)

O motor foi refatorado para permitir que a Ravena assuma diferentes “personalidades técnicas” dependendo da demanda.

- **Especialistas Carregados:**
 - `python` : Otimizado para sintaxe e algoritmos.
 - `security` : Focado em auditoria e blindagem de código.

- `logic` : Especialista em raciocínio puro e resolução de problemas.
 - **Troca Dinâmica:** O sistema agora alterna entre adaptadores LoRA sem necessidade de recarregar o modelo base (GPT-2/BitNet), economizando memória.
-

3. Sistema Multi-Agentes: Orquestrador Soberano

Implementamos um orquestrador que atua como o “Córtex Pré-Frontal” da Ravena, roteando solicitações para agentes especializados.

Fluxo de Decisão:

1. *Recebe a pergunta do usuário.*
 2. *Analisa palavras-chave e intenção.*
 3. *Roteia para o agente especialista (ex: `Cyber Sentinel` para segurança).*
 4. *O agente consulta o ChromaDB e gera a resposta com o modelo específico.*
-

4. Integração de APIs e Ferramentas (Tool Use)

A Ravena agora interage com o mundo externo através do `ToolManager`.

- **Sandbox de Execução:** Execução local segura de código Python com *timeout* e isolamento.
 - **APIs Financeiras:** Consulta em tempo real de cotações de moedas via *AwesomeAPI*.
 - **Busca na Web:** Estrutura integrada para pesquisa via *SerpAPI*.
 - **Utilidades:** Módulos de clima e notícias para suporte diário.
-

5. Estabilidade e Segurança: Protocolo Anti-Alucinação

Corrigimos os loops de repetição (“Aroa of the Wild”) através de ajustes finos nos parâmetros de geração:

- **Repetition Penalty:** 1.5 (Forte restrição a repetições).
- **Temperature:** 0.4 (Foco técnico e determinístico).

- **No-Repeat N-Gram:** 3 (Impede sequências repetitivas de 3 palavras).
 - **Lockdown V2.2:** Blindagem contra comandos maliciosos injetados via prompt.
-

6. Infraestrutura de Testes Padronizada

O projeto agora segue padrões profissionais de engenharia de software.

- **Pasta `/tests`:** Scripts organizados e separados do código-fonte.
 - **Pytest Integration:** Execução automatizada de toda a suíte de testes com um único comando.
 - **Configuração Global:** Arquivo `conftest.py` para gestão de ambiente.
-

Status do Sistema: 100% Operacional e Potencializado. **Arquiteto:** Manus AI (via Instrução do Usuário) **Data:** 05 de Abril de 2026