

Recomendação de Modelos de Linguagem para a Arquitetura Ravena AI

Autor: Manus AI

Data: 13 de Abril de 2026

1. Introdução

A arquitetura Ravena AI v3.0.0, um ecossistema de inteligência evolutiva, demonstrou a necessidade crítica de substituir o modelo GPT-2, que se mostrou inadequado para lidar com a complexidade e as demandas de raciocínio dos seus agentes. Este relatório tem como objetivo analisar modelos de linguagem avançados, com base no documento "Análise Técnica de Fronteira: Llama 3.1 70B e a Ascensão dos Modelos de Próxima Geração no Ecossistema NVIDIA e Open-Source" ¹, e nas capacidades da Oracle Cloud Infrastructure (OCI), para recomendar a melhor solução para os agentes Dev, Busca 360, Day Trade e o componente de chat.

2. Requisitos da Arquitetura Ravena AI

A Ravena AI opera com três agentes principais e um sistema de chat, cada um com requisitos distintos para um modelo de linguagem:

- **Agente Dev:** Necessita de capacidades robustas de raciocínio lógico, compreensão de código, matemática e resolução de problemas complexos para auxiliar no desenvolvimento e manutenção da arquitetura.
- **Agente Busca 360:** Requer processamento de linguagem natural (PNL) avançado para monitoramento global de notícias, redes sociais e dados on-chain. A capacidade de lidar com longas janelas de contexto é crucial para sintetizar informações de diversas fontes sem perda de dados.
- **Agente Day Trade (via Ponte de Dados):** A precisão e a capacidade de orquestração são vitais. O modelo deve ser capaz de interpretar sinais complexos, coordenar-se com o Agente Busca 360 e garantir a execução blindada das operações, minimizando alucinações e erros.
- **Chat (Geral):** Exige um modelo com alta fluência, capacidade multilíngue e bom raciocínio para interações com usuários, fornecendo respostas coerentes e úteis.

3. Modelos Candidatos e suas Vantagens

Com base na análise do documento fornecido 1 e na pesquisa sobre o suporte da OCI 2, os seguintes modelos foram considerados:

Modelo	Arquitetura	Janela de Contexto	Vantagens para Ravena AI	Suporte OCI
Llama 3.1 70B	Densa	128k tokens	Bom para raciocínio geral e desempenho em português.	Nativo
Llama 4 Scout	MoE (16 experts)	10M tokens	Excelente para RAG massivo e análise de grandes volumes de dados (Busca 360).	Nativo
Nemotron 3 Ultra	Híbrida Mamba-MoE	1M tokens	Alta precisão em fluxos multi-etapas e automação complexa.	Nativo
DeepSeek V3	MoE (671B params)	128k tokens	Otimizado para codificação, matemática e raciocínio complexo (Agente Dev).	Nativo
Kimi K2.5	MoE Transformer	256k tokens	Capacidade nativa de orquestração de agentes (Agente Day Trade).	Importável
Qwen 3.5 (397B)	MoE	128k tokens	Excelente desempenho multilíngue e raciocínio (Chat, Busca 360, Dev).	Nativo

Tucano 2	Densa (0,5 a 3,7B)	N/A	Leve, bom desempenho em português para tarefas de baixa complexidade.	Importável
----------	--------------------	-----	---	------------

4. Recomendação Final

Para a arquitetura Ravena AI, a abordagem mais eficaz é a utilização de **modelos especializados** para cada agente, complementados por um modelo robusto para o chat. Considerando o custo-benefício e o suporte da Oracle Cloud, a seguinte combinação é recomendada:

4.1. Modelo Principal para Agentes e Chat: Qwen 3.5 (397B)

O **Qwen 3.5 (397B)** é a recomendação principal devido à sua **excelente capacidade multilíngue e de raciocínio**, o que o torna ideal para o chat e para as tarefas gerais dos agentes Dev e Busca 360. Sua arquitetura MoE (Mixture-of-Experts) oferece um bom equilíbrio entre desempenho e eficiência, sendo suportado nativamente na OCI com hardware A100_80G_X2 ².

4.2. Modelo Complementar para Orquestração: Kimi K2.5

Para a **Ponte de Dados** e a coordenação entre o Agente Busca 360 e o Agente Day Trade, o **Kimi K2.5** é altamente recomendado. Sua **capacidade nativa de orquestração de agentes (Agent Swarm)** ¹ pode simplificar significativamente a lógica de comunicação e execução, reduzindo a complexidade do `signal_bridge.py` e minimizando alucinações em operações críticas. Embora seja um modelo importável na OCI, sua funcionalidade específica justifica a integração.

4.3. Considerações para o Agente Busca 360 (Contexto Longo): Llama 4 Scout ou Nemotron 3 Ultra

Para o Agente Busca 360, que lida com RAG massivo e análise de grandes volumes de dados, o **Llama 4 Scout** (10M tokens) ou o **Nemotron 3 Ultra** (1M tokens) são opções superiores devido às suas janelas de contexto extremamente longas ¹. Se o orçamento permitir, a integração de um desses modelos especificamente para o Agente Busca 360 maximizaria a capacidade de análise sem fragmentação de contexto. Ambos são suportados na OCI, com o Llama 4 Scout exigindo hardware H100 para seu potencial máximo ¹.

5. Plano de Implementação Sugerido

1. **Implantação do Qwen 3.5 (397B) na OCI:** Configurar o Qwen 3.5 como o modelo padrão para o chat e para as tarefas gerais dos agentes Dev e Busca 360, utilizando o serviço OCI Generative AI com GPUs A100_80G_X2.
2. **Integração do Kimi K2.5 para Orquestração:** Importar o Kimi K2.5 para a OCI e integrá-lo ao `signal_bridge.py` para gerenciar a comunicação e a coordenação entre os agentes Busca 360 e Day Trade.
3. **Avaliação e Otimização do Agente Busca 360:** Monitorar o desempenho do Qwen 3.5 no Agente Busca 360. Se a janela de contexto se tornar uma limitação, considerar a migração para o Llama 4 Scout ou Nemotron 3 Ultra, avaliando o custo-benefício do hardware H100.
4. **Refatoração da Lógica dos Agentes:** Adaptar o código dos agentes para aproveitar as capacidades avançadas dos novos modelos, especialmente a orquestração do Kimi K2.5.
5. **Testes Rigorosos:** Realizar testes extensivos em ambiente de laboratório (IQ Option) para validar a precisão e a estabilidade dos novos modelos antes da implantação em operações com capital real.

6. Conclusão

A substituição do GPT-2 por modelos mais avançados e especializados é um passo fundamental para a evolução da Ravena AI. A combinação do **Qwen 3.5 (397B)** para tarefas gerais e chat, com o **Kimi K2.5** para orquestração, oferece um caminho robusto e eficiente. A flexibilidade da Oracle Cloud para importar e hospedar esses modelos garante que a Ravena AI possa escalar e otimizar seu desempenho, superando as limitações atuais e atingindo um novo patamar de inteligência evolutiva.

7. Referências

- [1] [Análise Técnica de Fronteira: Llama 3.1 70B e a Ascensão dos Modelos de Próxima Geração no Ecossistema NVIDIA e Open-Source]
(file:///home/ubuntu/upload/ComparativodeModelosdeLinguagemAvançados.pdf)
- [2] Oracle Cloud Infrastructure Generative AI - Supported Models for Import